Slide 11 · Trợ lý AI: cách giải thích, câu hỏi dự kiến và công cụ BA đề xuất

Câu hỏi **kỹ thuật** nằm ở `PW_AI_Assistant_QA_ky_thuat.md`.

Nguồn: BRD (FR-030, NFR-001), sơ đồ D7.1 và D7.2, `web/docs/ai-assistant-rag.md`, `web/docs/ai-rag-production-design.md`, bản demo trong `web/js/assistant.js`.

1. Giải thích slide trong 1 phút

*"Trợ lý AI trả lời ba loại việc: hỏi đáp về PW, tra NFT của chính người dùng, và gợi ý danh hiệu theo mục đích. BRD yêu cầu phản hồi trong 2 đến 5 giây. Em chia dữ liệu thành hai loại: **tài liệu quy tắc** (giá, điểm, ví, KYC) thì đưa vào kho tri thức để tìm; **số liệu sống** (điểm, hạng, NFT của người hỏi) thì không đưa vào kho mà đọc trực tiếp qua hàm chỉ đọc, theo quyền của người đăng nhập, để luôn đúng. Bản demo chạy trong trình duyệt: phần tìm tài liệu là thật, phần viết câu trả lời là giả lập. Bản thật sẽ dùng mô hình ngôn ngữ và máy chủ trung gian. Trợ lý không tư vấn đầu tư, pháp lý, thuế."*

Ba ý cần nhớ: (1) tách tài liệu và số liệu sống; (2) không bịa số, không có dữ liệu thì nói không có; (3) demo giả lập bước viết câu trả lời, nói thẳng.

2. Câu hỏi dự kiến và cách trả lời

A. Về vai trò BA và phạm vi

Câu hỏi	Gợi ý trả lời
Vì sao PW cần trợ lý AI?	Người dùng mới phải hiểu Class, giá, giảm giá, điểm, ví, chuyển NFT. Trợ lý giảm việc phải hỏi hỗ trợ, và gợi ý Title theo mục đích mua. Yêu cầu nằm trong đề bài và BRD (FR-030).
Với tư cách BA, em quyết định gì trong phần AI?	Em quyết **trợ lý được làm gì và không được làm gì**: nguồn trả lời, quyền dữ liệu, từ chối tư vấn đầu tư, thời gian phản hồi, cách đo chất lượng. Em không chọn công nghệ; em đề xuất để nhóm kỹ thuật chốt.
BRD nói gì về AI?	FR-030: hỏi đáp, tra NFT, hướng dẫn, gợi ý Title; NFR-001: phản hồi 2–5 giây. Phụ lục BRD chốt phạm vi: trả lời từ tài liệu nền tảng, tra NFT của mình và thông tin công khai, không tư vấn đầu tư, pháp lý, thuế.
Có điều gì ngoài BRD không?	Có. Prototype còn một tính năng điền sẵn đơn mua hoặc tặng khi người dùng gõ lệnh; người dùng vẫn tự bấm thanh toán. Đây là phần thêm cho vui, **ngoài BRD** (BRD ghi trợ lý chỉ đọc). Nếu bị hỏi, nói thẳng như vậy.

B. Về kiến trúc

Câu hỏi	Gợi ý trả lời
RAG là gì, vì sao dùng?	Thay vì bắt mô hình "nhớ" luật của PW, hệ thống **tìm các đoạn tài liệu liên quan rồi đưa vào câu hỏi**, mô hình trả lời dựa trên các đoạn đó. Tài liệu đổi thì sửa tài liệu, không phải huấn luyện lại.

Câu hỏi	Gợi ý trả lời
Vì sao không huấn luyện (fine-tune) mô hình riêng?	Tốn công, khó cập nhật khi quy tắc đổi, và vẫn có thể bịa. RAG cập nhật bằng cách sửa tài liệu và có nguồn để kiểm.
Vì sao tách tài liệu và số liệu sống?	Số liệu (điểm, hạng, NFT) đổi từng phút và cần đúng tuyệt đối. Tìm theo "gần nghĩa" dễ trả sai số hoặc tên. Nên số liệu đọc qua hàm truy vấn, tài liệu mới vào kho tìm kiếm.
Vector database là gì? Có cần ngay không?	Là nơi lưu các đoạn tài liệu dạng vector để tìm theo nghĩa. Với 19 tài liệu hiện nay chưa cần: có thể đưa thẳng toàn bộ vào lời nhắc hệ thống. Em thiết kế sẵn vì khi kho tài liệu lớn lên (BRD, SRS, chính sách theo thẩm quyền, nhiều ngôn ngữ) sẽ cần.
Luồng D7.1 và D7.2 khác nhau thế nào?	D7.1 là **nạp tri thức**: viết hoặc sửa tài liệu, duyệt, chia đoạn, tạo vector, kiểm thử rồi mới bật. D7.2 là **trả lời**: kiểm tra câu hỏi, đọc số liệu sống nếu cần, tìm tài liệu, viết câu trả lời có dẫn nguồn, kiểm tra lại.
Bản demo khác bản thật ở đâu?	Demo: tìm tài liệu bằng BM25 (khớp từ khoá), kho là mảng trong trình duyệt, bước viết câu trả lời là **giả lập** (ghép câu liên quan nhất), chặn bằng quy tắc. Bản thật: tìm kết hợp vector và từ khoá, vector database, mô hình ngôn ngữ, máy chủ trung gian giữ khoá API, kiểm tra đầu vào bằng một mô hình nhỏ.

C. Về độ chính xác và an toàn

Câu hỏi	Gợi ý trả lời
Làm sao AI không bịa?	Ba lớp: chỉ trả lời dựa trên đoạn tài liệu và số liệu được đưa vào; luôn dẫn nguồn; không có dữ liệu thì nói rõ là không có và không bao giờ đoán số. Số liệu lấy từ hàm, không từ trí nhớ của mô hình.
AI có xem được dữ liệu của người khác không?	Không. Hàm tra dữ liệu cá nhân chạy theo quyền của người đăng nhập. Ở bản thật, mã người dùng lấy từ phiên đăng nhập trên máy chủ, **không** tin mã do trình duyệt gửi lên. Thông tin công khai của pháp nhân thì ai cũng tra được trên Directory.
Người dùng cố "bẻ khoá" (prompt injection) thì sao?	Mọi chữ người dùng nhập và nội dung tài liệu được coi là dữ liệu, không phải lệnh; có bước kiểm tra đầu vào và kiểm tra câu trả lời. Em nói thẳng: bộ chặn trong demo là quy tắc đơn giản nên dễ bị lách; bản thật cần thêm một lượt phân loại bằng mô hình.
AI có tư vấn đầu tư không?	Không. Hỏi kiểu "mua Title nào lời hơn" thì từ chối nhẹ nhàng và chỉ giải thích quy tắc. Gợi ý Title chỉ dựa trên **mục đích** (từ thiện, đầu tư chiến lược, kết nối thương vụ).
AI có thể mua hoặc chuyển NFT thay người dùng không?	Không. Theo BRD trợ lý chỉ đọc. Giao dịch luôn do người dùng tự xác nhận.

Câu hỏi	Gợi ý trả lời
Nếu tài liệu có thông tin cũ?	Tài liệu chỉ ghi **quy tắc**, mọi con số đổi được đều đọc sống. Khi quy tắc đổi (giá, điểm, chuyển NFT) phải sửa tài liệu cùng lúc, rồi chạy lại bộ câu hỏi kiểm thử.

D. Về hiệu năng, chi phí, chất lượng

Câu hỏi	Gợi ý trả lời
2 đến 5 giây có đạt được không?	Tìm kiếm chỉ vài chục mili-giây; phần lớn thời gian là mô hình ngôn ngữ. Cách giữ trong mức này: dùng mô hình vừa đủ, trả lời **truyền dần** để người dùng thấy chữ ngay, đưa ít đoạn nhưng đúng. Đây là yêu cầu cần đo thật khi có bản chạy mô hình.
Chi phí thế nào?	Em chưa có số vì phụ thuộc mô hình, lượng câu hỏi và độ dài tài liệu. Cách kiểm soát: dùng bộ nhớ đệm cho lời nhắc hệ thống, mô hình nhỏ cho câu hỏi đơn giản, giới hạn số câu hỏi mỗi người. Con số cụ thể nhóm kỹ thuật tính sau khi chọn nhà cung cấp.
Đo chất lượng bằng cách nào?	Bộ **33 câu kiểm thử** chạy được ngay trong trình duyệt, đạt hết. Mỗi lần gặp lỗi thì thêm một câu vào bộ, và chạy lại mỗi khi đổi tài liệu, lời nhắc hoặc mô hình. Với câu quan trọng nên có người chấm.
Có hỗ trợ tiếng Việt không?	Demo chỉ hiểu tiếng Anh (tài liệu bằng tiếng Anh). Bản thật cần mô hình ngôn ngữ và mô hình vector hỗ trợ nhiều ngôn ngữ; đây là một quyết định cần chốt sớm.
Ai chịu trách nhiệm nội dung tài liệu?	Một người phụ trách nội dung (đề xuất Product Owner với Compliance). Mỗi thay đổi đi qua bước duyệt và kiểm thử trước khi bật (sơ đồ D7.1).

E. Câu hỏi khó (trả lời trung thực)

Câu hỏi	Gợi ý trả lời
Vậy bản demo có phải AI thật không?	Phần **tìm kiếm tài liệu và đọc số liệu sống là thật**; phần **viết câu trả lời là giả lập**, nên câu trả lời là vài câu trích nguyên văn, đôi khi thiếu vế. Mô hình ngôn ngữ thật sẽ viết trôi chảy hơn; em nói rõ để không gây hiểu nhầm.
Nếu mô hình trả lời sai thì sao?	Có nguồn kèm theo để kiểm, có nhật ký câu hỏi và câu trả lời để rà soát, và người dùng luôn có đường liên hệ hỗ trợ. Với việc nhạy cảm (tiền, KYC) trợ lý chỉ giải thích quy tắc, không quyết định thay hệ thống.
Vì sao chọn cách này mà không phải "chatbot có sẵn"?	Chatbot thông thường không biết số liệu riêng của người dùng và không bảo đảm đúng quy tắc của PW. Cách này gắn với dữ liệu thật và có kiểm soát quyền truy cập.

3. BA đề xuất dùng những công cụ gì để xây trợ lý AI

Lưu ý trung thực: BRD không chỉ định công nghệ AI. Bảng dưới là **đề xuất của BA** theo kiến trúc RAG thông dụng. Nhóm kỹ thuật chốt sau khi thử nghiệm, so sánh chi phí và kiểm tra yêu cầu bảo mật. Tên sản phẩm chỉ là ví dụ.

Lớp	Việc cần làm	Đề xuất của BA	Phương án khác	Tiêu chí chọn
Mô hình ngôn ngữ	Viết câu trả lời từ tài liệu và số liệu	**Claude** của Anthropic (mô hình cỡ vừa cho câu trả lời, cỡ nhỏ cho phân loại câu hỏi)	GPT của OpenAI, Gemini của Google	Độ chính xác khi bám tài liệu, tiếng Việt, độ trễ, chính sách dữ liệu, giá
Mô hình vector (embedding)	Biến đoạn tài liệu thành vector	Voyage AI hoặc OpenAI embeddings; nếu cần tiếng Việt chọn loại **đa ngôn ngữ**	Cohere, BGE-M3 (tự chạy)	Chất lượng tiếng Việt, chi phí, phải dùng **cùng một mô hình** khi nạp và khi tìm
Cơ sở dữ liệu vector	Lưu và tìm đoạn tài liệu	**PostgreSQL + pgvector** (cùng cơ sở dữ liệu với phần còn lại của PW, hỗ trợ tìm từ khoá)	Pinecone, Qdrant	Quy mô nhỏ (hàng trăm tài liệu), muốn ít hệ thống phải vận hành
Tìm kiếm	Tìm đúng cả mã chính xác	**Tìm lai**: vector + từ khoá (mã như `#PW-2026-INV-10233`, `PW-ORG-0081` cần khớp chính xác)	Chỉ vector	Mã và tên pháp nhân hay trượt khi chỉ dùng vector
Máy chủ trung gian	Giữ khoá API, xác thực, gọi hàm đọc dữ liệu	Hàm serverless (Vercel, Cloudflare Workers hoặc AWS Lambda)	Máy chủ riêng	Khoá API không bao giờ nằm trong trình duyệt
Gọi hàm (tool use)	Đọc số liệu sống theo quyền	Chức năng **function calling** có sẵn của mô hình, hàm chỉ đọc, kiểm quyền ở máy chủ	Tự viết bộ điều phối	Đơn giản, ít mã, dễ kiểm
Khung điều phối	Nối các bước	Gọi trực tiếp SDK của nhà cung cấp, ít mã	LangChain, LlamaIndex	Quy trình chỉ vài bước nên khung nặng chưa cần
Bảo vệ đầu vào, đầu ra	Chặn tư vấn đầu tư, dữ liệu người khác, prompt injection	Quy tắc + **một lượt phân loại bằng mô hình nhỏ**; kiểm tra câu trả lời có nguồn	Dịch vụ guardrails chuyên dụng	Chi phí thêm một lượt gọi so với rủi ro
Quản lý tài liệu	Viết, duyệt, phiên bản hoá tài liệu	Viết bằng Markdown trong kho Git, duyệt bằng pull request; job nạp tự chạy khi có bản mới (D7.1)	Notion, Confluence	Có lịch sử thay đổi và người duyệt

Lớp	Việc cần làm	Đề xuất của BA	Phương án khác	Tiêu chí chọn
Kiểm thử chất lượng	Bộ câu hỏi chuẩn, chạy mỗi lần đổi	Bộ 33 câu hiện có, mở rộng dần; công cụ đánh giá như Promptfoo hoặc Ragas khi có bản thật	Chấm tay bằng bảng tính	BA **sở hữu bộ câu hỏi và tiêu chí đạt**
Quan sát và nhật ký	Xem câu hỏi, đoạn tìm được, độ trễ	Langfuse hoặc LangSmith (che dữ liệu nhạy cảm)	Nhật ký tự viết	Quyền riêng tư, truy vết khi trả lời sai

Công cụ BA dùng để làm phần này (không cần lập trình): draw.io (sơ đồ D7.1 và D7.2), bảng tính (bộ câu hỏi kiểm thử, ghi kết quả đạt hoặc không), Postman (thử các hàm đọc dữ liệu khi có API), và để thử nhanh một trợ lý mẫu trước khi đầu tư kỹ thuật có thể dùng công cụ không cần mã như Dify, Flowise hoặc Claude Projects. Các công cụ này chỉ để **thử ý tưởng**, không thay thế thiết kế có kiểm soát quyền dữ liệu.

Lộ trình BA đề xuất: 1. **Giai đoạn 1:** đưa toàn bộ 19 tài liệu vào lời nhắc hệ thống (không cần vector), thêm hàm đọc số liệu sống, dùng một mô hình ngôn ngữ. Đo độ chính xác bằng bộ câu hỏi. 2. **Giai đoạn 2:** khi tài liệu tăng (BRD, SRS, chính sách theo thẩm quyền, nhiều ngôn ngữ), chuyển sang tìm lai với pgvector. 3. **Giai đoạn 3:** thêm đánh giá liên tục, nhật ký, giới hạn số câu hỏi, rà soát bảo mật.

4. Số liệu và câu có thể nói chắc chắn

- FR-030 và NFR-001 (2–5 giây).
- 19 mục tài liệu trong kho; bộ 33 câu kiểm thử.
- Hai sơ đồ D7.1 (nạp tri thức) và D7.2 (trả lời).
- Demo: phần tìm tài liệu là thật (BM25), phần viết câu trả lời là giả lập.

Không nên nói: con số chi phí, độ chính xác phần trăm, hay "đã chọn" một nhà cung cấp cụ thể, vì chưa có dữ liệu thật.